

Université de Strasbourg
UFR de mathématique et d'informatique
Master Mathématiques et applications — Parcours **Statistique**

Mémoire de M1

**Juger une stratégie de bourse :
un protocole statistique de validation sur
données dépendantes**

Auteur : Joseph MANELA

Encadrant : Nicolas Poulin (Ingénieur de recherche)

Année universitaire : 2025–2026

3 août 2026

Table des matières

Introduction	1
1 Mesurer la dépendance qui menace le jugement	3
1.1 La base des trades	3
1.2 Les rendements sectoriels	5
1.3 La structure de dépendance, mesurée	6
1.3.1 Canal 1 — la dépendance de titre	6
1.3.2 Canal 2 — la dépendance de marché	7
1.3.3 Canal 3 — la dépendance temporelle	8
2 Juger les stratégies malgré la dépendance : une escalade de prudence	10
2.1 Chaque stratégie bat-elle le hasard ?	10
2.1.1 La question posée à l’outil	10
2.1.2 Les méthodes qui y répondent	10
2.1.3 Résultats	13
2.2 Le verdict survit-il à la dépendance des trades ?	14
2.2.1 La question posée à l’outil	14
2.2.2 Les méthodes qui y répondent	14
2.2.3 Résultats	24
2.3 Lecture du verdict : le marché est-il prévisible ?	26
2.4 Positionnement dans la littérature financière	26
2.5 Synthèse du chapitre	27
3 Du jugement à l’outil : le protocole, ses limites, ses suites	28
3.1 Le protocole récapitulé	28
3.2 Limites assumées	28
3.3 Perspectives	30
Conclusion	32
Bibliographie	33

Introduction

But du mémoire

Lors de mon stage en entreprise j'ai eu la consigne de créer un agent IA capable de faire du trading, c'est-à-dire un programme autonome qui décide seul d'acheter ou de vendre des titres en bourse. J'ai alors décidé de donner à mon agent des capacités d'analyse statistique. Après avoir créé le nécessaire pour qu'un agent puisse passer des ordres et avoir accès à différentes données du marché, j'ai estimé qu'il fallait qu'il soit capable d'évaluer les stratégies de trading qu'il établirait.

Je vais présenter dans ce rapport l'outil d'évaluation de stratégies que j'ai donné à mon agent.

L'objectif de cet outil n'est pas de découvrir une stratégie de trading rentable. Il est de construire un enchaînement de méthodes capable de déterminer, pour une stratégie quelconque qu'on lui soumet, si l'avantage qu'elle affiche est réel, ou bien s'il ne vient que du hasard d'échantillonnage ou de la dérive du marché.

Autrement dit, la contribution revendiquée est méthodologique : la chaîne de tests, sa justification et la vérification de ses conditions d'application.

Les dix stratégies d'analyse technique utilisées dans ce rapport, auxquelles s'ajoutera un témoin, ne constituent pas l'objet d'étude mais un banc d'essai : elles fournissent des jeux de données réels permettant de montrer que l'outil discrimine correctement — qu'il sait rejeter ce qui ne tient pas et retenir ce qui résiste à l'analyse. Les résultats obtenus sont donc présentés à titre d'illustration du bon fonctionnement du protocole, et non comme des recommandations d'investissement.

Pour s'assurer que l'outil ne rejette pas tout par excès de sévérité, on lui soumettra aussi un témoin dont l'avantage est réel par construction.

Les trois menaces qui pèsent sur le jugement

La première difficulté tient à la dérive du marché. Le premier réflexe pour juger une stratégie est d'examiner si elle est rentable. Un gain positif la ferait « marcher ». Ce raisonnement est pourtant trompeur, car encore faut-il que ce gain dépasse ce qu'une entrée au hasard aurait rapporté.

Ici les stratégies sont appliquées aux titres du S&P 500, l'indice des 500 grandes capitalisations

américaines, dont la tendance est haussière sur la période étudiée. Cette dérive haussière est un problème car une stratégie peut effectuer des gains sans avoir capté le moindre signal. C'est pourquoi on calculera non pas les gains mais plutôt l'avantage qu'apporte chaque stratégie.

La deuxième provient du nombre de tests. Plus on teste de stratégies, plus le risque d'obtenir au moins un faux positif augmente. Ce problème sera traité à la section 2.1 à l'aide de la correction de Bonferroni.

La troisième, sans doute la plus délicate, est la dépendance des données. De nombreuses méthodes statistiques imposent en condition l'indépendance des variables, or ici les trades sont dépendants sous différents aspects, comme la période, le titre et même le secteur ; cette difficulté sera mesurée au chapitre 1, puis neutralisée au chapitre 2.

On est forcé de prendre en compte ces trois difficultés, sous peine d'un verdict trop optimiste. C'est leur traitement conjoint qui fait de ce protocole un véritable outil de validation.

Démarche du mémoire

On commence par le chapitre 1, où je présente d'abord les données sur lesquelles on va travailler, les 45 008 trades et l'*edge* qui les compare au hasard. On y mesure ensuite les trois canaux par lesquels ces trades se ressemblent. Cet ordre n'est pas anodin. Tant qu'on n'a pas chiffré ce qui menace les tests, on ne peut pas savoir de combien il faudra les corriger.

Le chapitre 2 est le cœur du travail. On applique d'abord le test habituel, celui qu'on utiliserait sans se poser de question. Puis on reprend une à une les conditions qu'il suppose et on regarde ce que devient le verdict quand elles ne sont pas remplies. Chaque méthode ajoutée est plus exigeante que la précédente, et une stratégie doit toutes les franchir. C'est ce que j'appelle l'escalade de prudence.

Le chapitre 3 sort enfin du cas particulier de ces onze stratégies pour présenter la procédure elle-même, avec ce qu'elle ne sait pas faire et ce qu'il faudra lui ajouter.

Chapitre 1

Mesurer la dépendance qui menace le jugement

1.1 La base des trades

Tout au long de ce rapport, on appliquera les méthodes à notre base de données. Celle-ci a été obtenue en appliquant différentes stratégies sur des données antérieures. Cette méthode se nomme le *backtesting*, et consiste à vérifier si notre stratégie a repéré un signal de prédiction du marché.

Ici nous appliquons 10 stratégies techniques classiques ainsi qu'une stratégie oracle témoin, soit onze stratégies au total. La stratégie oracle utilise les données futures pour effectuer des trades uniquement gagnants, afin de vérifier si notre protocole laisse passer une stratégie dont le signal fonctionne réellement. Les 10 autres stratégies, elles, effectuent un trade à une date fixée en utilisant uniquement les données précédant cette date.

TABLE 1.1 – Les onze stratégies du banc d’essai et l’indicateur sur lequel chacune repose.

Stratégie	Fondée sur
<code>rsi_classic</code>	indicateur RSI (seuils 30/70)
<code>rsi_strict</code>	indicateur RSI (seuils 20/80)
<code>rsi_trend</code>	indicateur RSI avec filtre de tendance (MM200)
<code>ma_crossover</code>	croisement de deux moyennes mobiles
<code>db_bottom</code>	figure en double creux
<code>dt_top</code>	figure en double sommet
<code>hs_inverse</code>	figure épaule-tête-épaule inversée
<code>hs_classic</code>	figure épaule-tête-épaule
<code>sr_breakout</code>	cassure d’une résistance
<code>sr_breakdown</code>	cassure d’un support
<code>oracle</code>	témoin : connaît le cours futur (triche)

J’ai alors choisi d’appliquer ces stratégies de trading aux grandes capitalisations américaines présentes dans le S&P 500. Cet indice suit les 500 plus grandes sociétés cotées aux États-Unis, ce qui représente ici 501 titres, quelques sociétés étant cotées avec deux catégories d’actions. C’est un ensemble sur lequel on peut investir avec peu de risque : même si le cours de chacune de ces actions peut chuter individuellement, l’indice lui-même reste relativement stable et possède une tendance haussière.

Pour qu’une stratégie soit validée, il faut qu’elle ait de meilleurs résultats qu’une stratégie au hasard et que cela ne soit pas dû à notre échantillonnage. Ici la tendance est haussière, ce qui nous amène à la première difficulté mentionnée dans l’introduction : comment évaluer une stratégie lorsque la tendance est haussière ?

Pour répondre à cette problématique, on va simuler le hasard. À chaque trade réalisé, on associe 200 trades fictifs de même exposition (même titre, même durée, même sens), mais dont la date d’entrée est tirée au sort ; la moyenne de leurs rendements définit le gain du hasard pour ce trade.

On définit alors, pour chaque trade, son *edge* comme le rendement effectivement obtenu par la stratégie (éventuellement négatif) diminué de ce gain du hasard :

$$\text{edge} = \text{gain de la stratégie} - \text{gain du hasard}.$$

Un *edge* positif signifie que la stratégie a fait mieux qu’une entrée au hasard de même exposition : son *timing* apporte une information que la seule dérive du marché n’explique pas.

On obtient ainsi une base de données contenant, pour chaque stratégie, entre 978 et 8 513 trades effectués entre janvier 2010 et juillet 2026, pour un total de 45 008 trades. Dans nos données, chaque ligne correspond à un trade, c’est-à-dire une position ouverte puis fermée par une stratégie sur un titre : la stratégie achète l’action à une date donnée, la conserve un certain temps, puis la

revend. C’est cette ligne qui constituera notre unité statistique dans tout le reste du rapport. On y associe les indications suivantes : le titre (*ticker*), la stratégie employée, le secteur, les dates d’entrée et de sortie, la durée de détention, le régime de marché et le contexte à l’entrée (volatilité, RSI, distance à la moyenne mobile), le rendement et l’avantage (*edge*) sur un tirage aléatoire équivalent.

TABLE 1.2 – Description des variables d’un trade, illustrées sur un trade réel de la base (achat du titre A par la stratégie `rsi_classic`).

Variable	Nature	Signification	Exemple
<code>ticker</code>	qualitative (501 mod.)	le titre traité (une même action revient dans plusieurs trades)	A
<code>strategy</code>	qualitative (11 mod.)	la stratégie ayant produit le trade	<code>rsi_classic</code>
<code>sector</code>	qualitative (11 mod.)	le secteur d’activité du titre	Santé
<code>entry_date</code>	date	date d’achat	2011-08-11
<code>exit_date</code>	date	date de revente	2012-01-20
<code>holding_days</code>	quantitative	durée de détention, en jours	162
<code>regime_entry</code>	qualitative	régime du marché à l’entrée	baissier
<code>vol_entry</code>	quantitative	volatilité du titre à l’entrée	0,043
<code>rsi_entry</code>	quantitative	niveau de l’indicateur RSI à l’entrée	30,1
<code>dist_ma200</code>	quantitative	écart à la moyenne mobile sur 200 jours	−0,210
<code>return_net</code>	quantitative	rendement net réalisé par la stratégie	+0,187
<code>rand_return</code>	quantitative	rendement d’une entrée au hasard équivalente	+0,078
<code>edge</code>	quantitative	avantage = <code>return_net</code> − <code>rand_return</code>	+0,109
<code>win</code>	binaire	trade gagnant (1) ou perdant (0)	1

1.2 Les rendements sectoriels

Pour étudier la dépendance des données, on a besoin de données par secteur. Un secteur regroupe les sociétés qui exercent le même type d’activité et qui réagissent donc aux mêmes événements. Le S&P 500 en compte onze, parmi lesquels la technologie, la santé, l’énergie, ou encore les services aux collectivités qui rassemblent les fournisseurs d’électricité, d’eau et de gaz. Une hausse du prix du pétrole touchera ainsi toutes les sociétés du secteur de l’énergie en même temps.

Sur chacun de ces secteurs on établit une courbe du rendement journalier, obtenu en moyennant chaque jour les rendements des titres qui le composent. Ces données seront utilisées d’une part dans le canal 2 du paragraphe 1.3.2, pour mettre en évidence le facteur marché, c’est-à-dire la

part des mouvements qui est commune à tous les secteurs ; et d'autre part au paragraphe 2.3, pour examiner si le marché est prévisible à partir de son propre passé.

1.3 La structure de dépendance, mesurée

Les tests que nous utiliserons au chapitre 2 ne fonctionnent que si les données sont indépendantes. Ici les données sont dépendantes par titre, par date et par durée. Le réflexe du sondage impose de décrire son plan d'échantillonnage avant d'estimer quoi que ce soit, c'est pourquoi on mesure ces trois dépendances maintenant, avant les tests. On les examine l'une après l'autre, chacune formant ce que nous appellerons un canal.

1.3.1 Canal 1 — la dépendance de titre

Deux trades d'un même titre sont liés par la gestion de la société ainsi que par l'image de la société à l'extérieur. Ces deux trades subissent les mêmes chocs propres à la société (résultats, décisions de direction, litiges) indépendamment du moment où ils sont ouverts. On appellera cet effet la dépendance de titre : nos données constituent alors un tirage par grappes, où chaque grappe est un titre.

Reste à mesurer l'ampleur de cette ressemblance. Pour cela on va définir l'estimateur suivant, appelé corrélation intra-grappe, qui repose sur la décomposition de la variance étudiée en analyse de la variance [Sch59] :

$$\hat{\rho} = \frac{\text{MSB} - \text{MSW}}{\text{MSB} + (n_0 - 1) \text{MSW}},$$

où MSB (*Mean Square Between*) est la variation entre les titres, donc inter-grappes, c'est-à-dire la moyenne des écarts d'*edge* d'un titre à l'autre ; et MSW (*Mean Square Within*) est la variation à l'intérieur d'un titre, donc intra-grappe, c'est-à-dire la moyenne des écarts d'*edge* entre les trades d'un même titre. Deux cas se présentent alors. Si les trades d'un même titre ne se ressemblent pas plus que ceux de titres différents, la variation est identique à l'intérieur des titres et entre eux, et l'on obtient $\text{MSB} \approx \text{MSW}$. S'ils se ressemblent (dépendance intra-titre), la variation à l'intérieur d'un titre s'effondre tandis que la variation entre les titres subsiste, et l'on obtient $\text{MSB} > \text{MSW}$.

On pourrait prendre un simple quotient de MSB et MSW et lorsqu'il vaut 1, cela signifierait l'indépendance. Mais un écart à 1, qu'il soit de 0,1, de 3 ou de 100, ne se rattache à aucune échelle. On ne saurait dire s'il traduit une dépendance forte ou faible. Pour obtenir une réponse du type « 13,4 % du résultat est dû à une dépendance de grappe », on préfère la formule vue précédemment, qui ramène la mesure à une valeur comprise entre 0 et 1.

Le terme n_0 correspond à la taille moyenne des grappes, c'est-à-dire au nombre de trades par titre, corrigée de l'inégalité des tailles de grappes. Il pondère la variation intra-titre au dénominateur, ce qui ramène la mesure entre 0 et 1 : plus les grappes contiennent de trades, plus n_0 est grand, et plus il faut de contraste entre les titres pour conclure à une dépendance.

Appliqué à nos données, cet estimateur, reporté au tableau 1.3 en fin de section, donne un $\hat{\rho}$

quasi nul pour la plupart des stratégies, mais atteignant 0,134 pour `rsi_strict`.

La dépendance par le titre est donc négligeable pour toutes les stratégies, excepté `rsi_strict`. Un $\hat{\rho}$ faible ne garantit toutefois pas l'indépendance des trades : il n'écarte que ce premier canal, les deux suivants restant à examiner.

1.3.2 Canal 2 — la dépendance de marché

La deuxième dépendance que l'on va mesurer dans ce canal est la dépendance du moment. Des trades ouverts au même moment peuvent être liés parce qu'ils subissent la même journée de bourse : à une même période, différentes actions changent de valeur conjointement, et les trades effectués sont alors liés par le marché.

Cette dépendance ne s'observe pas directement sur les trades, mais sur le marché lui-même. Si les secteurs bougent ensemble, alors des trades ouverts au même moment, quel que soit leur secteur, subissent la même poussée. Pour la mesurer, on utilise donc les données introduites au point 1.2, c'est-à-dire les rendements quotidiens par secteur. On calcule alors les corrélations des secteurs deux à deux, puis on en fait la moyenne ; on obtient une corrélation de 0,70. Ce chiffre élevé signifie que les secteurs sont largement corrélés : lorsqu'un secteur bouge, le marché a tendance à bouger dans le même sens, et inversement, lorsque le marché suit une tendance, la plupart des secteurs la suivent aussi.

On utilise ensuite la méthode de l'ACP [LMP06] sur les onze secteurs, de façon à mettre en évidence les plus grandes corrélations (figure 1.1). Cette méthode calcule les axes qui captent la plus grande variance et les met en lumière. En l'appliquant ici, on observe un premier axe qui capte 73 % de la variance totale, le long duquel tous les secteurs progressent ensemble : c'est le mouvement global du marché. On a ensuite un deuxième axe, nettement moins important, qui sépare les secteurs cycliques, réagissant fortement au marché, de ceux qui sont défensifs, c'est-à-dire qui ne bougent pas beaucoup quelle que soit la situation du marché. On pourrait donner en exemple de secteur cyclique la technologie, qui dépend du pouvoir d'achat ; et comme secteur défensif les services aux collectivités (électricité, eau, gaz), dont la consommation reste constante, que le marché soit haussier ou en crise.




FIGURE 1.1 — ACP des onze rendements sectoriels. Sur le nuage de droite, les triangles désignent les secteurs cycliques et les disques les secteurs défensifs.

Sur l'histogramme de gauche, la première barre écrase toutes les autres, elle capte à elle seule 73 % de la variance, contre moins de 8 % pour la deuxième. Sur le nuage de droite, tous les secteurs se situent du même côté de l'axe horizontal (la première composante), ce qui confirme qu'ils progressent ensemble ; le second axe (vertical) les répartit entre secteurs défensifs et cycliques.

Cette cause commune n'est donc pas une hypothèse mais une mesure : 73 % des mouvements sont portés par une force unique. Deux trades ouverts au même moment subissent largement le même sort, ce qui les rend dépendants du marché.

1.3.3 Canal 3 — la dépendance temporelle

Dans la suite du rapport, on va avoir besoin d'agrèger les trades par mois. Or les trades durent : en moyenne 123 jours, avec une médiane de 53 jours, et plus de 78 % d'entre eux dépassent un mois. Un même trade, encore ouvert, est donc compté dans plusieurs mois consécutifs ; deux mois voisins partagent ainsi des trades communs et se ressemblent d'un mois à l'autre. Même agrégées par mois, les observations ne sont donc pas indépendantes. C'est pourquoi on va mesurer la corrélation d'un mois à l'autre.

Pour cela, on utilise l'autocorrélation d'ordre 1, notée $\hat{\rho}(1)$: on décale la série mensuelle d'un mois et on corrèle la série avec elle-même ainsi décalée. Elle mesure donc à quel point un mois ressemble au précédent. On obtient les valeurs suivantes.

TABLE 1.3 — Les dépendances mesurées, stratégie par stratégie : corrélation intra-titre $\hat{\rho}$ (canal 1) et autocorrélation mensuelle $\hat{\rho}(1)$ (canal 3).

Stratégie	$\hat{\rho}$ intra-titre	$\hat{\rho}(1)$ mensuelle
oracle (témoin)	0,053	0,18
db_bottom	0,000	0,36
dt_top	0,000	0,38
hs_classic	0,087	0,15
hs_inverse	0,001	0,31
ma_crossover	0,003	0,56
rsi_classic	0,000	0,23
rsi_strict	0,134	0,03
rsi_trend	0,010	0,20
sr_breakdown	0,051	0,11
sr_breakout	0,004	0,05

Le $\hat{\rho}(1)$ est de 0,56 pour **ma_crossover**, sa valeur la plus forte, tandis qu'il est faible pour **rsi_strict** (0,03). La dépendance temporelle est a priori forte pour les stratégies à trades longs, faible pour celles à trades courts. Attention : ces valeurs élevées ne traduisent pas une prévisibilité du marché, mais le chevauchement mécanique des trades qui durent.

Les trois canaux de dépendance sont désormais mesurés. Aucun n'est systématiquement élevé. La dépendance de titre reste souvent proche de zéro, et même l'autocorrélation temporelle s'efface pour les stratégies à trades courts. Mais chacun se manifeste fortement pour certaines stratégies,

la dépendance de titre pour `rsi_strict`, la dépendance de marché pour toutes, la dépendance temporelle pour `ma_crossover` ; et le chapitre 2 montrera qu'ils suffisent à renverser des verdicts.

On peut maintenant juger les stratégies en sachant exactement ce qui menace les tests.

Chapitre 2

Juger les stratégies malgré la dépendance : une escalade de prudence

Ce chapitre traite la question : parmi les dix stratégies d'analyse technique, auxquelles s'ajoute le témoin, lesquelles produisent un avantage (*edge*) significativement positif ? On applique d'abord le test de référence sous ses hypothèses standard, puis on met à l'épreuve, une à une, ses conditions d'application — en s'appuyant sur la structure de dépendance mesurée au chapitre 1. On terminera en interrogeant le marché lui-même, pour savoir si le verdict obtenu était prévisible.

2.1 Chaque stratégie bat-elle le hasard ?

2.1.1 La question posée à l'outil

La première question posée à l'outil est donc : l'avantage moyen affiché par une stratégie est-il réel, ou n'est-il qu'un accident d'échantillonnage ? On la formalise en confrontant la moyenne de l'*edge* à la valeur zéro, ce qui conduit au test de Student présenté ci-dessous.

2.1.2 Les méthodes qui y répondent

Test de Student

Lorsque l'on obtient un *edge* moyen positif, on cherche à savoir si la stratégie constitue réellement une prédiction, ou si cela est dû à l'aléa de l'échantillon.

Il faut ici distinguer deux quantités : l'*edge* moyen théorique μ_{edge} , c'est-à-dire la vraie valeur (inconnue) gouvernant la stratégie, et sa moyenne observée $\bar{e}$, calculée sur notre échantillon de trades (connue). On se pose la question suivante : à partir de la valeur observée $\bar{e}$, peut-on conclure que la vraie valeur μ_{edge} est positive ?

Le test de Student [Stu08] à un échantillon répond à cette question en confrontant μ_{edge} à une valeur de référence fixée à zéro (zéro = aucun avantage sur le hasard). Sa mise en œuvre suppose

deux conditions : que l'*edge* vérifie un critère de normalité, et que les trades soient indépendants les uns des autres. La première sera assouplie par le TCL (ci-après) ; la seconde, plus délicate, sera examinée en section suivante. On oppose ainsi deux hypothèses :

$$\begin{cases} H_0 : \mu_{edge} = 0 & (\text{le vrai } edge \text{ est nul : pas mieux que le hasard}), \\ H_1 : \mu_{edge} > 0 & (\text{le vrai } edge \text{ est positif : avantage réel}). \end{cases}$$

Le test est unilatéral : seul un avantage strictement positif nous intéresse.

Pour trancher, on définit t comme étant le nombre d'erreurs-types nécessaires pour faire basculer l'*edge* moyen de zéro vers celui obtenu dans notre échantillon :

$$t = \frac{\bar{e}}{s/\sqrt{n}} \sim t_{n-1} \quad \text{sous } H_0.$$

Sous H_0 (*edge* nul), t suit une loi de Student à $n - 1$ degrés de liberté. On évalue alors la p-value, c'est-à-dire la probabilité d'obtenir un t au moins aussi grand que celui observé si H_0 était vraie.

Si la p-value est très faible, le hasard n'est plus une explication crédible de l'*edge* moyen positif observé.

On tranche alors sur le fait que l'*edge* moyen théorique est positif, et que la stratégie permet donc de faire mieux que le hasard.

On a dit précédemment que le test de Student nécessitait que l'*edge* suive une loi normale. On cherche à vérifier cette condition, dans un premier temps avec le test de Shapiro–Wilk, puis dans un second temps à l'aide du théorème central limite (TCL). En effet, le test de Shapiro–Wilk a peu de chances de valider cette hypothèse : la taille conséquente de l'échantillon déstabilise ce test, alors qu'elle renforce au contraire le TCL.

Test de normalité de Shapiro–Wilk

Le test de Shapiro–Wilk [SW65] est un test de normalité qui consiste à comparer deux mesures de dispersion : d'une part les écarts à la moyenne, d'autre part l'ordre des valeurs. Ces deux mesures ne coïncident que si l'hypothèse de normalité est vraie. On oppose ainsi deux hypothèses :

$$\begin{cases} H_0 (W \simeq 1) : \text{l}'edge \text{ suit une loi normale,} \\ H_1 (W \ll 1) : \text{l}'edge \text{ ne suit pas une loi normale.} \end{cases}$$

On notera que, contrairement au test de Student, c'est ici H_0 qui correspond à la propriété recherchée (la normalité) : une p-value faible conduira donc à rejeter la normalité.

On pose alors la statistique $W = b^2/\text{SCE}$ comme rapport de ces deux mesures. Lorsque W est proche de 1, l'échantillon est compatible avec une loi normale.

Pour trancher sur la normalité, on procède de façon similaire au test de Student : on calcule la p-value d'obtenir notre W observé si la loi était normale ; si cette probabilité est trop faible,

alors on rejette l'hypothèse de normalité.

Appliqué à nos données, le test rejette la normalité pour les onze stratégies, comme le montre le tableau 2.1. La condition du test de Student n'est donc, en apparence, pas remplie. On remarque que même les stratégies dont le W est proche de 1, comme `dt_top` ($W = 0,95$), sont rejetées : à grand n , le moindre écart à la normale suffit à produire une p-value négligeable, ce qui justifie de recourir au théorème central limite plutôt qu'à ce test pour valider l'emploi de Student.

TABLE 2.1 – Statistique W et p-value de Shapiro–Wilk par stratégie (*edge* ; sous-échantillon de 5 000 trades lorsque $n > 5\,000$).

Stratégie	n	W	p (Shapiro)
<code>oracle</code> (témoin)	6 798	0,590	$6,8 \times 10^{-76}$
<code>db_bottom</code>	8 513	0,911	$2,7 \times 10^{-47}$
<code>dt_top</code>	7 381	0,950	$3,2 \times 10^{-38}$
<code>hs_classic</code>	1 065	0,886	$2,4 \times 10^{-27}$
<code>hs_inverse</code>	1 206	0,963	$6,4 \times 10^{-17}$
<code>ma_crossover</code>	5 417	0,498	$3,2 \times 10^{-80}$
<code>rsi_classic</code>	7 117	0,871	$1,5 \times 10^{-53}$
<code>rsi_strict</code>	978	0,717	$1,1 \times 10^{-37}$
<code>rsi_trend</code>	2 789	0,883	$1,2 \times 10^{-41}$
<code>sr_breakdown</code>	1 377	0,775	$8,0 \times 10^{-40}$
<code>sr_breakout</code>	2 367	0,843	$2,1 \times 10^{-43}$

Théorème central limite

Le rejet de Shapiro–Wilk porte sur la non-normalité de l'*edge* individuel. Mais comme le test de Student ne dépend que de la moyenne de l'*edge*, on peut se rabattre sur le théorème central limite [Sap06], qui garantit la quasi-normalité de la moyenne sur les grands échantillons, quelle que soit la loi de départ :

$$\frac{\bar{e} - \mu_{edge}}{\sigma/\sqrt{n}} \xrightarrow[n \rightarrow \infty]{} \mathcal{N}(0, 1).$$

Cette justification suppose un effectif suffisant ; un outil générique devrait écarter les stratégies trop peu fournies. Ici, n est compris entre 978 et 8 513 selon la stratégie, ce qui est largement suffisant. La condition réellement utile au test de Student est donc satisfaite, malgré le rejet de Shapiro–Wilk.

On remarque de plus que cette quantité est exactement celle du test de Student : sous H_0 ($\mu_{edge} = 0$), et en remplaçant l'écart-type théorique σ (inconnu) par son estimation s , on retrouve la statistique $t = \bar{e}/(s/\sqrt{n})$. Le théorème central limite justifie ainsi directement la forme et la validité du test de Student.

Correction de Bonferroni

Pour appliquer le test de Student, il faut fixer une valeur seuil pour la p-value. Lorsque l'on effectue un test isolé, on prend habituellement 0,05 : on estime que s'il n'y avait que 5 % de

chances d’obtenir un tel résultat sous H_0 , il est peu vraisemblable d’être tombé dessus par hasard, et l’on accepte alors le risque de rejeter H_0 .

Seulement, ici, on effectue 11 tests. Plaçons-nous dans le cas le plus défavorable où aucune stratégie n’a d’avantage réel (H_0 vraie pour les onze) : pour un test isolé, la probabilité de ne pas conclure à tort à un avantage est alors 0,95. En supposant les tests indépendants, la probabilité de ne commettre aucune erreur sur les 11 tests tombe à $0,95^{11} \approx 0,57$. Le risque de commettre au moins un faux positif sur l’ensemble s’élève donc à $1 - 0,95^{11} \approx 0,43$, ce qui est inacceptable.

Pour éviter cela, on raisonne en sens inverse : on fixe le risque global à 0,05 et l’on en déduit le seuil de chaque test. On s’appuie sur l’**inégalité de Boole**, selon laquelle la probabilité qu’au moins un événement se produise est inférieure ou égale à la somme de leurs probabilités individuelles. Pour garantir un risque global inférieur à 0,05, il suffit donc que la somme des seuils individuels soit égale à 0,05. En les prenant tous égaux, on obtient la **correction de Bonferroni** :

$$\alpha' = \frac{\alpha}{m} = \frac{0,05}{11} \approx 0,0045.$$

2.1.3 Résultats

TABLE 2.2 – Test de l’avantage moyen par stratégie (seuil Bonferroni $\approx 0,0045$).

Stratégie	n	$edge$ moyen	p (Student)	Verdict
oracle (témoin)	6 798	+0,0658	≈ 0	bat le hasard
rsi_classic	7 117	+0,0123	$1,2 \times 10^{-8}$	bat le hasard
rsi_strict	978	+0,1313	$5,5 \times 10^{-10}$	bat le hasard
rsi_trend	2 789	+0,0021	0,25	non
db_bottom	8 513	−0,0025	0,98	non
ma_crossover	5 417	−0,0248	≈ 1	non
(autres stratégies : $p > 0,45$, non significatives)				

Outre l’oracle témoin (qui bat le hasard de très loin, comme attendu), seules `rsi_classic` et `rsi_strict` survivent à la correction de Bonferroni.

Il est judicieux de rappeler que ce test vient uniquement répondre à la question de savoir si le $edge$ moyen positif est dû seulement à l’échantillon, auquel cas on conserve H_0 , ce qui signifie que la stratégie n’est pas gagnante. Toutefois dans le cas inverse, on pourra affirmer que la stratégie a capturé un signal, mais pas qu’elle est gagnante pour deux raisons. D’une part, un $edge$ positif ne signifie pas des gains positifs, mais simplement que l’on perd moins que le hasard. D’autre part, dû au fait que n est grand, la loi normale de la moyenne a une largeur qui s’écroule : on fait alors ressortir comme significatives des stratégies dont la moyenne d’ $edge$ n’est que très faiblement positive, que les frais suffiraient à rendre perdantes.

Surtout, ce verdict repose encore sur une condition que nous n’avons pas vérifiée, celle de l’indépendance des trades. C’est l’objet de la section suivante.

2.2 Le verdict survit-il à la dépendance des trades ?

2.2.1 La question posée à l'outil

On a appliqué de façon naïve le test de Student en supposant que les données étaient indépendantes. Or, comme nous l'avons mesuré au chapitre 1, nos données sont dépendantes par le titre, par le marché et d'un mois à l'autre. Ces dépendances empruntent en réalité deux chemins seulement, que nous appellerons les deux portes. La première est la porte de l'action, celle des trades ouverts sur un même titre. La seconde est la porte de la période, celle des trades ouverts à une même époque, qu'ils subissent ensemble le mouvement du marché ou qu'ils se prolongent sur les mêmes mois. Ce sont les deux seules voies par lesquelles deux trades peuvent partager une cause commune.

Le problème est que le test de Student traite alors les trades d'une stratégie comme autant d'informations distinctes, alors que ces informations se répètent en partie. L'erreur-type s'en trouve sous-estimée. Comme cette erreur-type sert à mesurer l'écart entre l'avantage observé et la valeur de référence, un dénominateur trop petit gonfle la statistique de Student et rend la p-value trop optimiste. Le risque de conclure à tort qu'une stratégie bat le hasard augmente d'autant.

Nous cherchons donc à savoir si le verdict positif obtenu pour `rsi_classic` et `rsi_strict` résiste lorsque l'on abandonne l'hypothèse d'indépendance. Pour cela, nous corrigeons d'abord l'erreur-type au moyen de l'effet de sondage, puis nous vérifions ce résultat par un rééchantillonnage qui ne suppose aucune forme particulière des données. Nous fermons ensuite chaque porte en regroupant les trades pour que chaque titre, puis chaque période, ne compte qu'une fois. Nous vérifions enfin que la porte de la période tient elle-même, en traitant la suite des avantages mensuels comme une série temporelle.

2.2.2 Les méthodes qui y répondent

Corriger l'erreur-type par l'effet de sondage

Comme on l'a vu au chapitre 1, dans nos données, les titres forment des grappes. On a également mesuré la corrélation intra-titre $\hat{\rho}$, qui dit à quel point les trades d'un même titre se ressemblent.

On va désormais introduire l'effet de sondage (design effect) qui est le rapport entre la variance d'un plan de sondage et la variance d'un plan de sondage de référence, typiquement le sondage aléatoire simple. Ici ce sera le rapport entre la variance réelle (les trades groupés par titre) et la variance de référence (sondage aléatoire simple).

$$\text{DEFF} = \frac{\text{Var}(\hat{\theta})}{\text{Var}_{\text{SAS}}(\hat{\theta})}.$$

Ici il s'agit d'un sondage à plusieurs degrés ; le cours de théorie des sondages établit qu'alors l'effet de sondage vaut

$$\text{DEFF} = 1 + (\bar{m} - 1) \hat{\rho},$$

où $\bar{m}$ désigne le nombre moyen de trades par titre, et $\hat{\rho}$ la corrélation intra-titre mesurée au chapitre 1. La variance réelle de la moyenne vaut DEFF fois celle que l'on obtiendrait sous indépendance. On doit alors considérer que l'on ne possède seulement que n_{eff} informations.

$$n_{\text{eff}} = \frac{n}{\text{DEFF}}.$$

Les largeurs d'IC sont alors multipliées par $\sqrt{\text{DEFF}}$ par rapport au plan de sondage de référence

$$\widehat{\text{se}}_{\text{corr}} = \frac{s}{\sqrt{n}} \sqrt{\text{DEFF}}.$$

On refait le test de Student de la section 2.1 avec cette erreur-type corrigée, en conservant le même seuil de Bonferroni.

Vérifier sans hypothèse de forme

La méthode ne va pas tester la dépendance intra-titre, mais plutôt évaluer son impact sur le *edge* moyen. Au lieu d'utiliser le test de Student, on va directement, à partir des grappes, essayer de créer une courbe de Gauss qui sera représentante de la répartition du *edge*, avec pour objectif de vérifier l'impact de la dépendance sur le *edge*. Car si la dépendance a un impact fort, alors notre cloche sera large et la probabilité d'être en dessous de zéro va augmenter.

Pour produire cette courbe, on va, comme à la méthode précédente, définir chaque titre comme étant une grappe à l'intérieur de laquelle les données sont dépendantes. On effectue alors un grand nombre de tirages, ici 4 000. À chaque tirage, on tire avec remise autant de titres que la stratégie en a mobilisés (soit environ cinq cents titres). Chaque titre peut être tiré plusieurs fois, auquel cas on prend autant de fois l'ensemble des trades qu'il contient. On calcule ensuite la moyenne des edges ainsi obtenue par ce tirage.

On obtient ainsi, après les 4 000 tirages, une cloche dont la moyenne ne diffère pas de la moyenne initiale : le tirage étant uniforme sur les titres, chaque trade a la même chance d'être repioché, si bien que la moyenne des tirages se recentre sur celle de départ. En revanche, la largeur de la cloche nous permet d'avoir une vision de l'impact de la dépendance intra-titre sur notre échantillon.

Il est utile de préciser que l'on calcule la moyenne des edges de l'ensemble des trades obtenus, afin de garder le poids qu'a chaque titre, contrairement à la méthode de la porte que l'on verra plus loin. C'est justement en gardant le poids de chaque titre que l'on conserve l'information de la dépendance intra-titre et que l'on met en valeur son influence sur le *edge* moyen.

En effet, lorsque la dépendance est très impactante, on obtient une cloche large qui va déborder sous zéro. On calcule alors le nombre de tirages qui passent sous zéro, que l'on divise par le

nombre total de tirages. Cette proportion est la p-value du test : si elle dépasse le seuil défini par la correction de Bonferroni, on rejette la stratégie.

Cette méthode suppose néanmoins que les titres soient indépendants entre eux, ce qui n'est pas le cas ici à cause du facteur marché. Elle reste toutefois un premier filtre légitime : en ignorant cette dépendance, le bootstrap sous-estime la largeur de la cloche et se montre donc trop permissif, si bien qu'une stratégie qui échoue déjà à ce stade est éliminée sans appel, tandis que les autres restent à départager par la porte suivante. Cette technique de rééchantillonnage est le bootstrap, proposé par Efron [Efr79].

Attention, cette méthode met en évidence le rôle de la dépendance intra-titre sur le *edge*. Cependant, le fait de conserver le poids de chaque titre nous laisse vulnérables. En effet, si la grande majorité des trades sont obtenus seulement sur un petit nombre de titres, alors nos tirages seront généralement similaires, et donc notre courbe sera étroite. C'est pourquoi, avec cette méthode, une cloche étroite ne suffit pas à conclure que l'avantage est réel. Pour lever ce doute, il faut retirer aux gros titres le poids que le nombre de leurs trades leur donne. C'est l'objet de la méthode suivante.

Fermer chaque porte en donnant un vote à chaque unité

Nous avons mesuré qu'il y a trois canaux de dépendance qui passent par deux portes. La première porte, celle de l'action ; la seconde porte, celle de la période, qui englobe la dépendance du marché ainsi que le chevauchement.

On utilise la méthode de l'agrégation, qui consiste à calculer l'avantage moyen de chaque grappe puis à appliquer le test de Student sur ces données, avec une seule voix par grappe quel que soit le nombre de trades qu'elle contient. Pour la porte de l'action, on agrégera par titre. Pour la porte de la période, on agrégera par mois : chaque trade est rattaché à son mois d'entrée, celui où le signal s'est déclenché et où la décision a été prise. On évite ainsi que la fluctuation du marché sur une même période, ou les trades qui se chevauchent, ne soient comptés comme plusieurs informations distinctes. Dans les deux cas, la dépendance à l'intérieur d'une grappe ne peut plus rien fausser, puisqu'un titre, ou un mois, ne pèse qu'une seule voix. En revanche, rattacher un trade à son seul mois d'entrée alors qu'il peut rester ouvert plusieurs mois lie les mois voisins entre eux : cette dépendance inter-mensuelle sera le sujet de la méthode suivante. N'oublions pas que le théorème central limite s'applique alors à ces moyennes de grappes, dont le nombre reste élevé : selon les stratégies, il reste 431 à 501 titres pour la porte de l'action et 138 à 197 mois pour celle de la période, ce qui est bien suffisant. Le protocole ayant vocation à juger les stratégies à venir, il signale toutefois le cas où une stratégie trop peu diffusée laisserait un nombre de grappes insuffisant pour invoquer le théorème : le verdict serait alors ininterprétable et non pas défavorable. Pour être validée, une stratégie doit franchir les deux portes, chacune au seuil de Bonferroni.

Cette technique fait perdre beaucoup d'information. Mais on privilégiera le risque de faux négatif à celui de faux positif.

Ayant déjà évalué la dépendance intra-titre par les méthodes DEFF et bootstrap, l'apport de

cette méthode sera de mettre en lumière les stratégies qui, comme nous l'avons expliqué à la fin de la méthode d'Efron, reposent uniquement sur quelques titres, car l'agrégation supprime le poids des titres.

On rejettera les stratégies qui ne passeront pas la fermeture des portes. Toutefois, une stratégie rejetée parce qu'elle dépend de certains titres en particulier pourra être réétudiée afin de peaufiner la sélection des trades. Il est possible qu'une stratégie ne soit efficace que sur un secteur en particulier. Il faudra évidemment faire attention au sur-apprentissage.

Une objection mérite d'être levée. La porte de l'action suppose les titres indépendants entre eux, ce qui est contestable puisque le marché explique une grande part de la variance : deux titres tradés au même moment subissent le même choc. Mais cette dépendance-là est de nature temporelle, deux titres ne sont liés que s'ils sont tradés à la même période, et c'est précisément ce que la porte de la période traite. Les deux portes se complètent donc, chacune prenant en charge une source, ce qui justifie de les poser toutes les deux.

Elles ne sont toutefois pas fermées simultanément : nous conduisons deux tests séparés plutôt qu'une agrégation croisée par titre et par mois, qui produirait des grappes bien plus petites et rouvrirait à moitié chacune des deux portes. La règle du ET est d'ailleurs plus exigeante, puisqu'une stratégie doit survivre à chaque source de dépendance prise isolément et traitée dans le pire des cas. Seule échapperait une dépendance propre à l'intersection, un effet qui n'existerait que pour un titre donné pendant un mois donné, et l'on voit mal comment un tel effet porterait à lui seul un avantage. Le traitement simultané des deux dimensions existe, c'est le double clustering de Petersen [Pet09], mais il sort du cadre des méthodes simples retenues ici ; nous y revenons en section 3.2.

Vérifier que la porte de la période tient elle-même

Comme nous l'avons mesuré au deuxième canal du chapitre 1, le marché explique 73 % de la variance : lorsqu'un événement survient, tout le marché réagit de façon similaire. L'agrégation mensuelle regroupe ainsi les trades déclenchés par un même contexte de marché, et rattacher chaque trade à son seul mois d'entrée garantit qu'aucun ne pèse dans deux grappes à la fois.

Ce rattachement règle le double comptage, mais non le recouvrement des périodes de détention. Nous avons vu au chapitre 1 que les trades se prolongent souvent au-delà d'un mois : un trade ouvert en janvier et clos en avril est rangé dans janvier, alors que son résultat dépend de ce qui s'est passé jusqu'en avril. La grappe de janvier porte donc de l'information sur les mois suivants, que la grappe de février porte également. Aucun trade n'est compté deux fois, et pourtant deux mois voisins partagent les mêmes conditions de marché ; avec 73 % de la variance expliquée par ces conditions communes, ce recouvrement suffit à les faire se ressembler.

La suite des avantages mensuels est donc autocorrélée, et le test de Student avec agrégation mensuelle pourrait être trop optimiste. On voudrait alors appliquer comme précédemment la méthode du DEFF pour corriger l'erreur-type. Mais nos données sont chronologiques : la dépendance y est ordonnée, un mois étant plus lié au précédent qu'à celui d'il y a cinq mois, là

où les trades d'un même titre étaient interchangeables. Un coefficient unique ne peut donc pas la décrire, et il nous faut une autre méthode.

Dans cette méthode nous voulons calculer, pour un mois t , l'impact moyen qu'ont les mois qui le précèdent, en cherchant jusqu'à six mois en arrière. Pour cela nous allons traiter cette suite comme une série temporelle. On supposera qu'il n'y a pas d'effet de saison, et surtout que le lien entre deux mois ne dépend que de leur écart et non de leur date, le mois de janvier réagissant comme les autres mois de l'année.

On mesure alors l'impact propre de chaque décalage par l'autocorrélation partielle (PACF), qui retranche l'influence des mois intermédiaires ; un mois peut en effet sembler lié à celui d'il y a deux mois par le seul fait qu'ils sont tous deux liés au mois qui les sépare. Cette autocorrélation partielle s'annule au-delà du dernier mois qui compte vraiment, ce qui nous donne le nombre de mois à retenir, puis l'impact de chacun d'eux. Ensuite, de la même façon que pour la méthode du DEFF, on corrigera l'erreur-type du test de Student avec agrégation mensuelle.

La méthode se déroule alors en trois temps, chacun porté par un outil : y a-t-il réellement une dépendance (test de Box et Pierce) ? peut-on la modéliser (stationnarité par Dickey-Fuller et KPSS, ordre par l'autocorrélation partielle, poids par Yule-Walker) ? de combien corriger (variance de long terme) ? Les tests de conditions qui jalonnent ce parcours sont menés au seuil usuel de 5 % ; le seuil de Bonferroni reste réservé au verdict final.

Test d'indépendance de Box et Pierce

Avant de corriger, encore faut-il qu'il y ait quelque chose à corriger. Le raisonnement du recouvrement rend l'autocorrélation plausible, il ne la rend pas certaine, et elle peut différer d'une stratégie à l'autre. Le protocole commence donc par poser directement la question à chaque série : les mois sont-ils indépendants ? Le test de Box et Pierce [BP70] y répond sur la série brute, sa statistique cumule les six premières autocorrélations, mises au carré pour que les positives et les négatives ne se compensent pas, et mises à l'échelle de la longueur de la série :

$$S_{BP} = T \sum_{h=1}^6 \hat{\rho}(h)^2,$$

où T est le nombre de mois de la série et $\hat{\rho}(h)$ l'autocorrélation d'ordre h , c'est-à-dire la corrélation entre la série et elle-même décalée de h mois.

Ce nombre de six décalages n'est pas choisi au hasard. La dépendance que nous cherchons vient du recouvrement des périodes de détention, un trade ouvert en janvier et clos en avril liant janvier aux mois suivants. Elle ne peut donc pas s'étendre au-delà de la durée des trades, qui dépassent rarement six mois. Regarder plus loin reviendrait à chercher un effet là où aucune cause ne peut le produire, tout en ajoutant du bruit à la statistique. Ce même plafond nous servira plus loin pour choisir l'ordre du modèle, et nous vérifierons en fin de méthode qu'aucune mémoire ne subsiste au-delà.

On oppose alors :

$$\begin{cases} H_0 (S_{BP} \text{ petit}) : \text{les mois sont indépendants,} \\ H_1 (S_{BP} \text{ grand}) : \text{au moins un décalage porte une autocorrélation.} \end{cases}$$

C'est H_0 qui porte ici la propriété recherchée.

Sous H_0 , chaque $\hat{\rho}(h)$ n'est que du bruit d'échantillonnage d'ordre $1/\sqrt{T}$: la somme S_{BP} suit alors une loi du khi-deux à six degrés de liberté. On calcule donc la p-value de notre S_{BP} observé ; si elle est trop faible, l'indépendance n'est plus une explication crédible.

Si l'indépendance n'est pas rejetée, la condition du test par agrégation mensuelle est remplie telle quelle : son verdict tient, et aucune correction n'est requise — on ne corrige que ce qui est mesuré, comme pour le DEFF. Si elle est rejetée, l'autocorrélation est réelle et la suite de la méthode s'applique.

Pour effectuer cette correction on va supposer que les mois sont tous similairement exposés aux mois qui les précèdent ; pourtant cette affirmation n'est vraie que si la série est stationnaire, c'est pourquoi on va effectuer deux tests pour vérifier la stationnarité de la série de chaque stratégie concernée.

Si une série ne l'était pas, on sortirait du domaine de validité de la méthode. Le protocole la signale et s'abstient de conclure plutôt que de produire un verdict fondé sur un impact moyen qui n'aurait pas de sens. Aucune de nos stratégies n'est dans ce cas, mais la situation peut se présenter pour une stratégie à venir.

Test de stationnarité de Dickey et Fuller augmenté

Ce test, comme le suivant, se calcule directement sur la série. Il consiste à calculer, par une simple régression du mois courant sur le mois précédent, un coefficient que nous noterons ϕ : $x_t = \phi x_{t-1} + \eta_t$. En remplaçant x_{t-1} par sa propre expression, puis en recommençant, on voit ce que devient un choc au fil du temps :

$$x_t = \eta_t + \phi \eta_{t-1} + \phi^2 \eta_{t-2} + \phi^3 \eta_{t-3} + \dots$$

Le mois courant est donc la somme de tous les chocs passés, chacun pesé par ϕ élevé à son ancienneté. Si ϕ est inférieur à 1, ces puissances tendent vers zéro : l'impact d'un mois sur ceux qui suivent décroît, la série oublie ses chocs et revient vers sa moyenne, elle est stationnaire. Si ϕ vaut 1, toutes les puissances valent 1 : chaque choc s'ajoute définitivement au niveau, la série dérive sans repère et n'est donc pas stationnaire. On oppose ainsi :

$$\begin{cases} H_0 (\phi = 1) : \text{les chocs s'accumulent, la série n'est pas stationnaire,} \\ H_1 (\phi < 1) : \text{les chocs s'estompent, la série est stationnaire.} \end{cases}$$

Le test est unilatéral : un ϕ supérieur à 1 décrirait une série explosive, cas sans objet ici. C'est

donc le rejet qui conclut à la stationnarité.

Comme pour le test de Student, la statistique est le nombre d'erreurs-types qui séparent le $\hat{\phi}$ estimé de la valeur 1 :

$$t_{DF} = \frac{\hat{\phi} - 1}{\widehat{se}(\hat{\phi})},$$

où $\hat{\phi}$ est le coefficient estimé par la régression et $\widehat{se}(\hat{\phi})$ son erreur-type, c'est-à-dire l'incertitude qui entoure cette estimation. Plus t_{DF} est négatif, plus $\hat{\phi}$ s'écarte de 1 vers le bas et plus H_0 devient implausible.

Cette statistique, que les auteurs eux-mêmes nomment rapport de Student, n'en suit pourtant pas la loi [DF79]. La raison tient à H_0 : sous cette hypothèse la série n'est justement pas stationnaire, sa variance croît avec le temps, et les conditions qui donnent la loi de Student ne sont plus réunies. Sa loi est alors celle que Dickey et Fuller ont établie et tabulée, et qui porte leur nom. La lecture reste ensuite la même : p-value confrontée au seuil, rejet si elle est trop faible.

Ce test suppose que les résidus de la régression ne soient plus autocorrélés ; on emploie pour cela sa version dite augmentée, qui ajoute des mois passés supplémentaires dans la régression jusqu'à les nettoyer. Reste à savoir combien : trop peu et la mémoire n'est pas absorbée, trop et chaque coefficient supplémentaire, estimé sur les mêmes données, ajoute du bruit. C'est le critère d'information d'Akaike [Aka74] qui arbitre :

$$AIC_k = 2 \ln \hat{\sigma}_k + \frac{k}{T},$$

où $\hat{\sigma}_k$ mesure l'erreur résiduelle du modèle à k retards. Le premier terme diminue quand le modèle colle mieux aux données, le second augmente avec le nombre de coefficients : on retient le k qui minimise la somme, de sorte qu'un retard n'est conservé que s'il apporte plus qu'il ne coûte. Sur nos séries, ce nombre va de zéro à neuf selon les stratégies : la condition est donc prise en charge par le test lui-même.

Test de stationnarité KPSS

À l'inverse, le KPSS [Kwi+92] cumule les écarts à la moyenne au fil du temps : si la série oscille autour d'un niveau fixe, ces cumuls se compensent et restent bornés, tandis qu'ils s'emballent dès que la série dérive. Ses hypothèses sont inversées :

$$\begin{cases} H_0 \text{ (cumuls bornés) : la série est stationnaire,} \\ H_1 \text{ (cumuls qui s'emballent) : la série n'est pas stationnaire.} \end{cases}$$

Comme pour le test de Shapiro–Wilk, c'est ici H_0 qui porte la propriété recherchée : c'est l'absence de rejet qui conclut à la stationnarité.

Sa statistique somme les carrés de ces cumuls, rapportés à la longueur de la série et à sa variance

de long terme, de sorte qu'elle reste petite quand les cumuls sont bornés et explose quand ils dérivent. Sa loi sous H_0 est, là aussi, tabulée par les auteurs : on rejette la stationnarité quand la statistique dépasse la valeur critique, c'est-à-dire quand la p-value passe sous le seuil.

Ce test demande de préciser autour de quoi la stationnarité est jugée ; nous la testons autour d'une constante et non d'une tendance, car rien ne laisse attendre qu'un avantage dérive régulièrement au fil des années.

Concordance des deux tests

Les deux hypothèses nulles étant opposées, chacun des tests protège l'autre de sa propre faiblesse : ne pas rejeter n'a jamais valeur de preuve, et un test seul ne distingue pas une série réellement stationnaire d'une série sur laquelle il manque de puissance. Nous ne concluons donc que lorsque les deux concordent ; s'ils divergent, le diagnostic sera tenu pour non concluant plutôt que pour défavorable.

Ces deux tests ne demandent aucun modèle, et c'est bien ainsi qu'il faut l'entendre : le ϕ de Dickey et Fuller ne sert qu'à trancher sur la racine unitaire et n'est pas conservé. Les impacts que nous recherchons sont d'une autre nature ; la stationnarité maintenant acquise nous donne le droit de les estimer.

Autocorrélation partielle et choix de l'ordre

On mesure l'impact propre de chaque décalage h par l'autocorrélation partielle $\hat{\tau}(h)$. Reste à décider quels décalages comptent vraiment. On procède décalage par décalage, en opposant :

$$\begin{cases} H_0 (\tau(h) = 0) : \text{le mois } t - h \text{ n'a pas d'impact propre,} \\ H_1 (\tau(h) \neq 0) : \text{il en a un.} \end{cases}$$

Sous H_0 , $\hat{\tau}(h)$ n'est que du bruit d'échantillonnage, approximativement normal et d'écart-type $1/\sqrt{T}$: la statistique $\sqrt{T} \hat{\tau}(h)$ suit donc une loi normale centrée réduite. On en tire, comme pour les tests précédents, la p-value de notre $\hat{\tau}(h)$ observé ; si elle passe sous le seuil de 5 %, l'absence d'impact n'est plus une explication crédible et le décalage est retenu. Cela revient à comparer $|\hat{\tau}(h)|$ à $q_{0,975}/\sqrt{T}$, avec $q_{0,975} \approx 1,96$ — c'est la bande de significativité que l'on trace sur les corrélogrammes. L'ordre retenu $\hat{p}$ est le dernier décalage significatif ; si des décalages intermédiaires ne le sont pas, ils sont conservés malgré tout, car on préfère surestimer la mémoire que la tronquer.

La recherche est plafonnée à six mois, pour la raison déjà donnée au test de Box et Pierce. Cet argument reste toutefois une plausibilité, non une preuve. Nous n'en resterons pas là : la validation du modèle, présentée plus bas, vérifiera qu'aucune mémoire ne subsiste au-delà de ce plafond.

Équations de Yule-Walker

L'ordre connu, on écrit le modèle autorégressif [BJ70] sur la série centrée : le mois courant est une somme pondérée des $\hat{p}$ mois précédents, plus un bruit,

$$x_t = \Phi_1 x_{t-1} + \cdots + \Phi_{\hat{p}} x_{t-\hat{p}} + \eta_t,$$

où x_t est l'avantage moyen du mois t (écarté de la moyenne de la série), Φ_i le poids du mois $t - i$ — l'impact propre que nous cherchions —, et η_t le bruit, c'est-à-dire la part du mois courant qu'aucun mois passé n'explique. Ces poids ne se lisent pas directement dans les données. Les autocorrélations, en revanche, se mesurent sans difficulté : il suffit de comparer la série à elle-même décalée. Les équations de Yule-Walker font le lien entre les deux. On les obtient en multipliant le modèle par x_{t-h} , le mois situé h crans en arrière, puis en prenant l'espérance : le bruit η_t disparaît, étant indépendant de tout ce qui précède, et il reste, pour chaque $h = 1, \dots, \hat{p}$:

$$\rho(h) = \Phi_1 \rho(h-1) + \Phi_2 \rho(h-2) + \cdots + \Phi_{\hat{p}} \rho(h-\hat{p}),$$

avec $\rho(0) = 1$ et $\rho(-k) = \rho(k)$, une série étant liée à elle-même de la même façon dans les deux sens. Chaque autocorrélation s'exprime ainsi en fonction des poids recherchés. Comme il y a autant d'équations que de poids inconnus, on y reporte les autocorrélations mesurées, on résout, et l'on remonte ainsi aux poids. Le cas d'un seul mois de mémoire est éclairant : le système se réduit à $\rho(1) = \Phi_1$, le poids est alors exactement l'autocorrélation mesurée.

Une équation supplémentaire, celle du décalage nul, donne l'amplitude du bruit :

$$\sigma_\eta^2 = \gamma(0) \left(1 - \sum_{i=1}^{\hat{p}} \Phi_i \rho(i) \right),$$

soit la variance de la série moins la part qu'expliquent les mois passés, autrement dit ce qui reste imprévisible.

Ce système n'a de sens que si la série est stationnaire. Parler de « l'autocorrélation à deux mois d'écart », c'est en effet supposer qu'il en existe une seule valeur, la même en 2010 qu'en 2020. Sans cette garantie, il en faudrait une par époque, et le système n'aurait plus de solution unique.

C'est la somme de ces poids qui nous intéresse, car elle mesure la persistance totale de la série : c'est elle qui dira de combien l'erreur-type du test mensuel doit être corrigée.

Variance de long terme et test de Student corrigé

Le modèle fournit alors une variance de la moyenne qui tient compte de la persistance, appelée variance de long terme :

$$\gamma_{\text{lr}} = \frac{\sigma_\eta^2}{\left(1 - \sum_{i=1}^{\hat{p}} \Phi_i\right)^2}, \quad \widehat{\text{Var}}(\bar{x}) \approx \frac{\gamma_{\text{lr}}}{T}, \quad \text{DEFF}_t = \frac{\gamma_{\text{lr}}}{\gamma(0)},$$

où σ_η^2 et les Φ_i sont le bruit et les poids estimés ci-dessus, T le nombre de mois et $\gamma(0)$ la variance de la série. Cette variance de long terme additionne toutes les autocovariances, là où la formule usuelle en s^2/T suppose au contraire des mois sans lien : si les poids sont nuls, le dénominateur vaut 1 et l'on retrouve la formule usuelle ; plus la persistance est forte, plus la correction est importante. Le rapport DEFF_t est l'exact analogue temporel de l'effet de sondage de la première méthode : un facteur qui dit combien de fois la variance de la moyenne est sous-estimée quand on ignore la dépendance — sur l'axe du temps cette fois, et obtenu par un modèle car la dépendance y est ordonnée.

Le test de Student de la porte de la période est alors repris tel quel, avec deux changements : l'erreur-type devient $\sqrt{\gamma_r/T}$, et le nombre de degrés de liberté est ramené à la taille effective $T_{\text{eff}} = T/\text{DEFF}_t$, comme pour le DEFF. La statistique diminue mécaniquement : une stratégie peut franchir la porte de la période et échouer ici. Le verdict se lit au même seuil de Bonferroni que les étapes précédentes.

Validation du modèle : Box et Pierce sur les résidus

Reste à vérifier que le modèle a bien capté toute l'autocorrélation, sans quoi la correction serait fondée sur une mémoire mal décrite. On dispose pour cela des résidus $\hat{\eta}_t$, c'est-à-dire ce que le modèle n'explique pas : pour chaque mois, la valeur observée moins celle que les mois précédents laissaient attendre. Le raisonnement est alors le même qu'au début de la méthode, mais appliqué à ce qui reste : si le modèle a bien absorbé toute la mémoire, les résidus n'en contiennent plus, et ils sont indépendants d'un mois à l'autre. On leur pose donc exactement la question qu'on avait posée à la série brute, avec le même test :

$$\begin{cases} H_0 (S_{\text{BP}} \text{ petit}) : \text{les résidus sont indépendants, le modèle a tout absorbé,} \\ H_1 (S_{\text{BP}} \text{ grand}) : \text{il subsiste de la mémoire, le modèle est inadéquat.} \end{cases}$$

La démarche est donc circulaire au bon sens du terme : le premier test demandait y a-t-il de la mémoire ?, celui-ci demande en reste-t-il ? Deux différences seulement. L'inspection porte sur quinze décalages et non plus six, comme le recommande la pratique usuelle [BP70] qui situe ce nombre entre quinze et vingt ; le plafond de six mois n'a donc rien pu laisser échapper. Et comme $\hat{p}$ coefficients ont été estimés sur ces mêmes données, ce qui rend les résidus artificiellement un peu plus propres, on retranche le nombre de paramètres du modèle : la statistique suit sous H_0 une loi du khi-deux à $15 - \hat{p}$ degrés de liberté.

Ne pas rejeter valide donc la correction. Un rejet signifierait au contraire un ordre trop faible ou une forme inadaptée ; le protocole le signale et s'abstient alors de conclure, comme pour la stationnarité.

Au terme de cette méthode, la condition d'indépendance entre mois, que la porte de la période supposait sans la vérifier, a donc été soit établie, soit prise en charge par une correction elle-même contrôlée. Rappelons que les conditions ne s'appliquent qu'à la branche qui les appelle : une stratégie dont l'indépendance mensuelle n'est pas rejetée conserve le verdict de la porte de la période sans qu'on ait à exiger d'elle ni stationnarité ni modèle, puisqu'aucune correction ne lui

est appliquée.

2.2.3 Résultats

On a vu précédemment que seules trois stratégies passaient le premier filtre du test de Student naïf, qui supposait l'indépendance. Analysons les résultats du protocole sur ces stratégies.

TABLE 2.3 – Diagnostic de dépendance intra-titre et test corrigé par l'effet de sondage, avec vérification par le bootstrap.

Stratégie	$\hat{\rho}$	DEFF	n_{eff}	p naïve	p corrigée	p bootstrap
oracle (témoin)	0,053	1,67	4076	≈ 0	≈ 0	$< 2,5 \times 10^{-4}$
rsi_classic	0,000	1,00	7 117	$1,2 \times 10^{-8}$	$1,2 \times 10^{-8}$	$< 2,5 \times 10^{-4}$
rsi_strict	0,134	1,15	848	$5,5 \times 10^{-10}$	7×10^{-9}	$< 2,5 \times 10^{-4}$
(autres stratégies : verdict « non » inchangé, $\hat{\rho} \leq 0,09$)						

Le $\hat{\rho}$ intra-titre mesuré au chapitre 1 était quasi nul pour l'ensemble des stratégies, à l'exception de **rsi_strict** (0,134). La correction DEFF, qui gonfle la variance en proportion de cette dépendance, ne change donc presque rien : **rsi_classic** et **rsi_strict** survivent toutes deux à cette première correction, et le bootstrap par grappes, qui ne fait aucune hypothèse sur la forme de la dépendance, confirme le verdict. Le témoin, lui aussi, franchit cette étape sans difficulté.

On continue alors le protocole sur ces trois stratégies.

TABLE 2.4 – Le test des deux portes : une unité réelle, un vote.

Stratégie	Porte action (k titres)		Porte période (k mois)		Verdict
	k	p_A	k	p_B	
oracle (témoin)	501	≈ 0	193	≈ 0	OUI
rsi_classic	501	0,059	195	0,039	non
rsi_strict	456	$3,9 \times 10^{-4}$	138	0,26	non
rsi_trend	495	0,22	175	0,29	non
sr_breakdown	457	0,37	184	0,94	non
(six autres stratégies : $p_A \geq 0,74$, toutes « non »)					

Ce tableau change la lecture du chapitre. L'oracle passe les deux portes de très loin (p_A et p_B pratiquement nuls) : son avantage, construit pour être réel, se retrouve aussi bien titre par titre que mois par mois. C'est le résultat attendu, mais il est important, car il montre que l'outil ne rejette pas tout par excès de prudence et qu'il sait dire « oui » quand l'avantage est effectivement là.

rsi_classic, en revanche, tombe aux deux portes ($p_A = 0,059$ et $p_B = 0,039$, loin du seuil de Bonferroni 0,0045). Les 7 117 trades de cette stratégie ne constituaient pas 7 117 témoignages indépendants, mais un nombre bien plus restreint de titres et de mois, chacun compté plusieurs fois. Dès que chaque titre, puis chaque mois, ne vote plus qu'une seule fois, l'avantage s'efface.

rsi_strict a un comportement différent : elle passe brillamment la porte de l'action ($p_A = 3,9 \times 10^{-4}$: son avantage est bien partagé par un grand nombre de titres), mais échoue à la porte de la période ($p_B = 0,26$). Son avantage est réel titre par titre, mais épisodique dans le temps, sans régularité mois après mois démontrable. En l'état, il n'est donc pas exploitable.

Le protocole écarte ces deux stratégies, mais avec une note signalant qu'elles présentent des résultats remarquables sur certains titres ou certains mois. Il faudra se garder du sur-apprentissage, mais peut-être existe-t-il un facteur qui expliquerait ces résultats. En l'état, on ne peut pas les laisser passer.

En dehors du témoin, plus aucune stratégie ne franchit les deux portes. Cela n'a rien d'étonnant : on opère sur les cinq cents plus grandes capitalisations des États-Unis et, comme ces actions ont une forte tendance à croître, il faut un résultat extrême pour dépasser le seuil de l'improbable.

TABLE 2.5 – Série mensuelle des *edge* : autocorrélation et test corrigé de la variance de long terme.

Stratégie	T	$\hat{\rho}(1)$	$\hat{p}$ (AR)	DEFF _{<i>t</i>}	p corrigée	p Box–Pierce
oracle (témoin)	193	0,18	0	1,0	$9,4 \times 10^{-85}$	0,16
ma_crossover	188	0,56	3	6,4	0,94	0,14
dt_top	197	0,38	1	2,2	0,97	0,69
db_bottom	197	0,36	1	2,1	0,82	0,90
hs_inverse	186	0,31	1	1,9	0,91	0,93
rsi_classic	195	0,23	1	1,6	0,08	0,93
rsi_strict	138	0,03	0	1,0	0,26	0,28
(quatre autres stratégies : DEFF _{<i>t</i>} ≤ 2,4, aucune significative)						

Cette dernière étape ne s'applique qu'aux stratégies encore en lice, celles qui auraient franchi les deux portes. Pour chacune, on se demande d'abord si les mois voisins sont réellement liés : le test de Box et Pierce sur la série brute tranche entre une série sans mémoire, qui conserve alors le verdict de la porte de la période sans correction, et une série autocorrélée, qui appelle une correction.

Le tableau montre que la moitié des séries seulement sont autocorrélées et suivent la branche corrigée, l'autocorrélation d'ordre un atteignant 0,56 pour **ma_crossover**. Les autres, dont l'oracle et **rsi_strict**, ne rejettent pas l'indépendance des mois : leur verdict de la porte de la période tient tel quel, sans correction.

Pour les séries autocorrélées, la correction n'est légitime que sous stationnarité. Le croisement des deux tests l'assure ici pour toutes : Dickey et Fuller rejette la racine unitaire ($p \leq 0,005$), tandis que le KPSS ne rejette pas la stationnarité. Après correction, aucun verdict ne bascule : la variance mensuelle était bien sous-estimée, d'un facteur allant jusqu'à 6,4 pour **ma_crossover**, mais aucune stratégie ne devient significative pour autant. Comme attendu, l'oracle franchit lui aussi cette dernière étape.

2.3 Lecture du verdict : le marché est-il prévisible ?

Aucune stratégie ne passe, et on peut se demander si c'est normal. Toutes celles que nous avons testées cherchent la même chose, un signal dans le passé du marché qui annoncerait la suite. Il est donc légitime de poser la question directement au marché lui-même, sans passer par les stratégies. Nous utilisons pour cela les rendements quotidiens introduits au paragraphe 1.2, en prenant la colonne du marché agrégé, soit 4 132 jours de cotation.

On applique le test de Box et Pierce à cette série, exactement comme on l'a fait sur les séries mensuelles. Le résultat est net, l'indépendance est rejetée très largement ($S_{BP} = 93,7$ sur six retards, soit une p-value indiscernable de zéro). Il y a donc bien de la mémoire dans le marché, et on pourrait croire que cela contredit tout ce qui précède.

C'est ici qu'il faut regarder l'amplitude et non la seule p-value. L'autocorrélation d'ordre un vaut $-0,08$, ce qui veut dire que la veille explique $0,6\%$ de ce qui se passe le lendemain. Le signe négatif indique un léger effet de rebond, une baisse ayant tendance à être suivie d'une hausse. Si l'on construit la stratégie qui exploite ce rebond, en pariant chaque jour contre le mouvement de la veille, elle rapporte $0,007\%$ par jour avant frais. Or le moindre aller-retour en coûte davantage, si bien que la stratégie devient perdante dès que l'on tient compte des frais les plus faibles.

Le marché est donc prévisible au sens statistique du terme, mais il ne l'est pas au sens où l'on pourrait en tirer de l'argent. C'est exactement ce que décrit l'efficiance faible au sens de Fama [Fam70], la dépendance qui subsiste étant trop ténue pour couvrir le coût de son exploitation. On retrouve ici, sur le marché lui-même, la mise en garde formulée au premier test, un grand échantillon rend significatif le moindre écart et il ne faut pas confondre significativité et taille d'effet.

Le verdict du protocole s'éclaire alors. Si le passé du marché ne contient presque rien d'exploitable, il est cohérent que des stratégies qui ne lisent que ce passé n'aient rien trouvé. Le protocole n'a donc pas été inutilement sévère, il a simplement constaté une absence qui était attendue.

2.4 Positionnement dans la littérature financière

Les outils de ce chapitre ont été construits à partir des seuls concepts de cours, sondages, analyse de la variance et séries temporelles, or ils coïncident avec les standards de l'économétrie financière.

L'agrégation par mois, une statistique par période puis l'inférence sur la série de ces statistiques, est exactement la démarche de Fama et MacBeth [FM73], standard du domaine. La variance de long terme estimée par le modèle autorégressif poursuit quant à elle le même objectif que les erreurs-types robustes à l'autocorrélation de Newey et West [NW87], dont elle est une version paramétrique, validée ici par le test de Box et Pierce.

Cette convergence est un argument en faveur du protocole. Les méthodes n'ont pas été choisies parce qu'elles étaient reconnues en finance, mais parce que le raisonnement statistique y menait ; le fait de retrouver au bout du chemin des outils que la discipline utilise déjà indique que ce raisonnement était le bon.

2.5 Synthèse du chapitre

Ce chapitre a procédé par une escalade de prudence. On commence par le test de Student, le point de départ le plus simple pour une telle analyse. Malgré ses hypothèses simplificatrices, il suffit déjà à écarter huit des onze stratégies étudiées.

On a ensuite dû prendre en compte la dépendance, restée jusque-là hors du champ du test. En reprenant les résultats du chapitre 1, qui avait mis en évidence trois canaux de dépendance se ramenant à deux portes, la dépendance entre les trades d'un même titre d'une part, celle liée au moment d'autre part, il a fallu accepter de perdre beaucoup d'information en agrégeant par titre puis par mois.

Cette agrégation aurait suffi s'il n'était pas resté, en outre, la dépendance entre mois voisins. Il a donc fallu appliquer une dernière correction, qui a elle-même exigé de vérifier la stationnarité des séries. Au terme de cette escalade, plus aucune stratégie ne subsiste en dehors du témoin. Le verdict positif du premier test ne tenait donc que par une condition qu'on n'avait pas vérifiée.

Ce résultat n'a rien de surprenant une fois qu'on a interrogé le marché lui-même. Son passé contient bien un peu d'information sur son avenir, mais tellement peu que les frais l'effacent. Des stratégies qui ne lisent que ce passé ne pouvaient donc pas trouver grand-chose.

Le chapitre suivant expose les limites de ce protocole, qui pourra certainement être perfectionné avec le temps.

Chapitre 3

Du jugement à l'outil : le protocole, ses limites, ses suites

3.1 Le protocole récapitulé

Les chapitres précédents ont jugé onze stratégies. Mais ce que je voulais donner à mon agent n'était pas ce verdict, qui ne concerne que ces stratégies-là. C'était la procédure qui a permis de le rendre.

Cette procédure ne fournit donc pas une stratégie gagnante, mais une manière de juger, réutilisable telle quelle sur tout signal futur de l'agent, qu'il soit technique, informationnel ou relationnel. Chaque étage répare une condition d'application précise, et le verdict n'est prononcé que si tous les étages concordent. Le tableau 3.1 la récapitule en six étages.

TABLE 3.1 – Le protocole de validation en six étages : chaque étage répare une menace identifiée, et le verdict exige de tous les franchir.

Étage	Menace traitée	Outil
1. <i>edge</i> apparié au hasard	dérive du marché	Monte Carlo apparié
2. Student unilatéral + TCL	variabilité d'échantillonnage	test de référence
3. Seuil de Bonferroni	multiplicité (11 tests)	contrôle du risque global
4. DEFF + bootstrap par grappes	dépendance intra-titre	sondages, rééchantillonnage
5. Les deux portes (titre, mois)	pseudo-réplication	agrégation équipondérée
6. Série mensuelle AR(p)	autocorrélation résiduelle	variance de long terme

3.2 Limites assumées

Aucune de ces limites n'invalide le verdict rendu ; chacune trace en revanche la frontière de ce que le protocole peut affirmer. On les regroupe en limites techniques, propres à la construction des données, et en limites statistiques, propres aux méthodes elles-mêmes.

Limites techniques

La première tient à la façon dont les stratégies ont été établies. Si l'on étudiait des stratégies dont les règles ont été optimisées sur les données mêmes qui servent ensuite à les juger, on tomberait dans le sur-apprentissage. Le risque est ici atténué, car les stratégies retenues sont des règles classiques à peu de paramètres, non ajustées sur l'échantillon ; il n'est pas pour autant nul, et une validation hors échantillon, où l'on fige les règles sur une période puis on juge sur la suivante, resterait nécessaire avant tout usage opérationnel.

Par ailleurs, les frais et les conditions d'exécution n'ont été modélisés que de façon simplifiée ; les intégrer plus finement rapprocherait le test des conditions réelles.

Enfin, la base ne contient que les sociétés présentes dans l'indice sur la période, les entreprises disparues en étant absentes. Ce biais du survivant est atténué par la construction appariée de l'*edge*, qui compare chaque trade au hasard sur le même titre, mais il subsiste.

Le S&P 500 pose d'ailleurs une difficulté voisine. Sa composition est prise telle qu'elle est aujourd'hui et appliquée à toute la période, alors qu'elle a changé au fil des années ; on juge donc les stratégies sur des titres dont on sait après coup qu'ils sont restés dans l'indice. Cela ne remet pas en cause le verdict, mais rappelle que l'univers de test n'est pas neutre, puisqu'il s'agit des plus grandes capitalisations américaines, celles qui ont le mieux traversé la période.

Limites statistiques

Le test de Student initial concède beaucoup d'incertitude, puisqu'il surestime la quantité d'information disponible en traitant les trades comme indépendants. Il a néanmoins suffi à écarter huit stratégies. Il suppose aussi un effectif assez grand pour invoquer le théorème central limite, condition d'autant plus importante qu'en finance les données ne suivent guère une loi normale.

Le contrôle du risque global par la correction de Bonferroni est adapté à un nombre restreint de stratégies déclarées à l'avance. Sur un univers de milliers de variantes essayées, le contrôle de la fouille de données exigerait plutôt un outil dédié comme le *Reality Check* de White [Whi00].

Une limite plus subtile tient à l'empilement des corrections. Chaque méthode a été conçue pour une seule source de dépendance : le DEFF et le bootstrap pour la dépendance intratitre, chaque porte pour sa propre dimension. Prises isolément, elles sont exactes ; utilisées ensemble sur des données où les dépendances coexistent, elles perdent la garantie de leur seuil nominal, et l'inférence de la correction mensuelle en particulier n'est plus exactement calibrée. Le protocole reste cependant fixe et applique toujours les mêmes étapes ; ce qui varie, c'est la lecture. Lorsqu'une dépendance se révèle négligeable sur un canal, le seuil nominal y demeure valide et la conclusion peut être chiffrée ; ce n'est que si les trois canaux se manifestaient fortement en même temps, leurs corrections se cumulant, que le risque global cesserait d'être chiffrable, et ce cas serait alors signalé. Comme la dépendance simultanée aux trois canaux reste faible dans nos données, on retient les verdicts obtenus.

Dans le prolongement de ce point, les deux portes sont fermées l'une après l'autre et non simultanément. Une dépendance qui n'existerait que pour un titre donné pendant un mois donné

échapperait donc au contrôle. Nous avons jugé ce cas peu vraisemblable, mais la méthode qui le traiterait directement existe, c'est le double clustering de Petersen [Pet09]. Elle demande un cadre de régression sur données de panel qui dépasse les méthodes simples retenues ici, et constitue à ce titre un prolongement naturel du protocole.

Il faut aussi noter ce que les portes font des stratégies dont l'avantage est concentré. En n'accordant qu'une voix à chaque titre et à chaque mois, elles écartent celles qui ne doivent leur résultat qu'à quelques titres très tradés ou à quelques mois exceptionnels. C'est bien l'effet recherché, puisqu'un tel avantage n'est pas généralisable en l'état. Mais le rejet ne signifie pas que la stratégie soit sans valeur. Il indique qu'elle demande une réétude, en cherchant ce que ces titres ou ces périodes ont en commun, avec le risque de sur-apprentissage que cela comporte et la nécessité d'une validation sur des données qui n'auraient pas servi à cette recherche.

La correction mensuelle, enfin, suppose des séries stationnaires. Aucune de nos stratégies n'est en défaut sur ce point, mais le cas peut se présenter pour une stratégie à venir. Le protocole le signale alors et s'abstient de conclure, plutôt que de produire un verdict fondé sur un impact moyen qui n'aurait pas de sens. Le même principe vaut lorsque le modèle autorégressif ne parvient pas à absorber toute la mémoire de la série.

Il faut enfin rappeler que la puissance élevée des grands échantillons rend le moindre écart significatif : significativité et taille d'effet doivent être distinguées avec soin. C'est ce que nous avons observé sur le marché lui-même, dont l'autocorrélation est très nettement significative sans être exploitable.

Face à chacune de ces limites, le protocole ne tranche pas au forceps : il préfère écarter une stratégie en signalant la réserve plutôt que de conclure sur une base fragile.

3.3 Perspectives

La première perspective est la création de nos propres stratégies. Elle suppose de séparer une zone d'apprentissage et une zone de test, en avançant période après période plutôt que par une validation croisée classique, qui mélangerait le futur et le passé. Le protocole devra être adapté en conséquence.

Il faudra aussi lui ajouter un garde-fou d'effectif, écartant en amont les stratégies trop peu fournies pour que le théorème central limite s'applique, car ni le test de normalité ni le théorème central limite ne permettent alors de conclure.

Une autre voie consiste à modéliser l'avantage en fonction du contexte, par exemple la probabilité de gain selon le régime de marché ou le secteur, ce qui prolongerait directement la piste des stratégies ciblées évoquée au chapitre 2. Cette voie a été écartée du présent travail par rigueur : sur des dizaines de milliers de trades dépendants, les p-values des coefficients d'une régression seraient trop optimistes, exactement le piège du chapitre 2. Les outils adaptés, modèles à effets mixtes ou équations d'estimation généralisées, dépassent le cadre de ce travail.

L'objectif est enfin de fournir à l'agent un maximum d'information, y compris des signaux tournés

vers l'avenir comme les projets de loi ou les signatures de contrats, ainsi que les relations d'avance et de retard entre titres, au sens de la causalité de Granger [Gra69]. Des travaux exploratoires ont été engagés sur ces fronts. Ce mémoire en constitue la fondation : il fournit l'outil qui permettra, tout du long, de vérifier les stratégies à venir.

Conclusion

L'objectif fixé en introduction n'était pas de découvrir une stratégie gagnante, mais de construire un protocole capable d'en juger une quelconque. Ce protocole est désormais construit, éprouvé, et il a rendu son verdict. Aucune des dix stratégies d'analyse technique ne démontre d'avantage réel une fois les conditions d'application vérifiées, seul le témoin franchissant tous les étages.

Le résultat central mérite d'être rappelé. Le test de référence déclarait deux stratégies gagnantes. La seule vérification de la condition d'indépendance a renversé les deux verdicts : l'une se révélait un faux positif né de la répétition d'une même information sur des milliers de trades, l'autre un avantage réel mais trop épisodique dans le temps pour être retenu. Dans le même temps, le témoin construit pour être gagnant a franchi chaque étage sans faiblir. Un outil de validation se juge à sa capacité d'attraper ses propres erreurs tout en reconnaissant le vrai : la démonstration est faite.

Une idée traverse l'ensemble de ce travail. La dépendance des données y a joué deux rôles opposés. Simultanée, portée par le facteur marché qui explique près des trois quarts des mouvements, elle était la nuisance qui faussait les tests, et il a fallu la mesurer puis la neutraliser pour juger proprement. Retardée, elle aurait au contraire été la ressource qu'une stratégie cherche à exploiter. Or nous avons vu que le marché en contient bel et bien, mais si peu que les frais suffisent à l'annuler. Neutraliser l'une, chercher l'autre, c'est la même statistique vue des deux côtés du même objet.

Le protocole est ainsi prêt à juger les prochains signaux de l'agent, en commençant par leur validation temporelle.

Bibliographie

- [Aka74] Hirotugu AKAIKE. « A New Look at the Statistical Model Identification ». In : *IEEE Transactions on Automatic Control* 19.6 (1974), p. 716-723.
- [BJ70] George E. P. BOX et Gwilym M. JENKINS. *Time Series Analysis : Forecasting and Control*. San Francisco : Holden-Day, 1970.
- [BP70] George E. P. BOX et David A. PIERCE. « Distribution of Residual Autocorrelations in Autoregressive-Integrated Moving Average Time Series Models ». In : *Journal of the American Statistical Association* 65.332 (1970), p. 1509-1526.
- [DF79] David A. DICKEY et Wayne A. FULLER. « Distribution of the Estimators for Autoregressive Time Series with a Unit Root ». In : *Journal of the American Statistical Association* 74.366 (1979), p. 427-431.
- [Efr79] Bradley EFRON. « Bootstrap Methods : Another Look at the Jackknife ». In : *The Annals of Statistics* 7.1 (1979), p. 1-26.
- [Fam70] Eugene F. FAMA. « Efficient Capital Markets : A Review of Theory and Empirical Work ». In : *The Journal of Finance* 25.2 (1970), p. 383-417.
- [FM73] Eugene F. FAMA et James D. MACBETH. « Risk, Return, and Equilibrium : Empirical Tests ». In : *Journal of Political Economy* 81.3 (1973), p. 607-636.
- [Gra69] Clive W. J. GRANGER. « Investigating Causal Relations by Econometric Models and Cross-spectral Methods ». In : *Econometrica* 37.3 (1969), p. 424-438.
- [Kwi+92] Denis KWIATKOWSKI et al. « Testing the Null Hypothesis of Stationarity against the Alternative of a Unit Root ». In : *Journal of Econometrics* 54.1-3 (1992), p. 159-178.
- [LMP06] Ludovic LEBART, Alain MORINEAU et Marie PIRON. *Statistique exploratoire multidimensionnelle*. Paris : Dunod, 2006.
- [NW87] Whitney K. NEWEY et Kenneth D. WEST. « A Simple, Positive Semi-definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix ». In : *Econometrica* 55.3 (1987), p. 703-708.
- [Pet09] Mitchell A. PETERSEN. « Estimating Standard Errors in Finance Panel Data Sets : Comparing Approaches ». In : *The Review of Financial Studies* 22.1 (2009), p. 435-480.
- [Sap06] Gilbert SAPORTA. *Probabilités, analyse des données et statistique*. 2^e éd. Paris : Technip, 2006.
- [Sch59] Henry SCHEFFÉ. *The Analysis of Variance*. New York : Wiley, 1959.
- [SW65] S. S. SHAPIRO et M. B. WILK. « An Analysis of Variance Test for Normality (Complete Samples) ». In : *Biometrika* 52.3-4 (1965), p. 591-611.
- [Stu08] STUDENT. « The Probable Error of a Mean ». In : *Biometrika* 6.1 (1908), p. 1-25.

- [Whi00] Halbert WHITE. « A Reality Check for Data Snooping ». In : *Econometrica* 68.5 (2000), p. 1097-1126.